

QQ 音乐样本数据分析报告

姓名：高子淇 学号：2025010481 班级：计54

结论概述与数据范围

本报告从项目爬取的 QQ 音乐歌曲、歌词和热门评论数据出发，完成三项分析：

- 1. 使用常规柱状图分析热门评论的发布时间分布；
- 2. 使用词云和标准化词频比较歌词与热门评论的语言重心；
- 3. 使用预训练文本向量、K-Means 和 t-SNE 分析歌词语义聚类，并列出生成各簇主题和典型歌曲。

原始数据文件为 `data/raw/song_list.json`，共包含 3835 首歌曲和 19151 条热门评论。由于这些数据是爬虫从平台中取得的部分数据，而且每首歌曲只保存了少量热门评论，报告中的结论只对本次样本负责，不能直接推广为 QQ 音乐全部歌曲或全部用户的规律。

三项分析采用的有效数据量不同：

分析项目	有效数据	被过滤数据	过滤原因
评论发布时间	19151 条评论	0 条	评论正文非空，且小时字段为 0 至 23
歌词词云	3821 首歌词	14 首	清洗或分词后没有有效词语
评论词云	19140 条评论	11 条	分词后没有有效词语
歌词语义聚类	3789 首歌词	46 首	清洗后少于 30 字符，或没有有效分词

歌词词云与歌词聚类的有效歌曲数不同，是因为聚类额外设置了 30 字符的最短歌词要求，并非数据统计错误。

公共数据处理

`analysis/utils` 为 `analysis/` 下的公共处理模块，包括：

- `load_from_json_dict(file: Path) -> list[dict]` 负责读取内容为 dict 的 JSON 文件
- `save_to_json(file: Path, content: dict | list) -> None` 负责存储数据到 JSON 文件
- `load_stopwords() -> set[str]` 负责加载停用词
- `clean_lyrics(lyrics: list[str]) -> str` 负责清洗歌词，去除空行、带制作信息标记的行以及同一首歌曲中完全重复的歌词行
- `tokenize(text: str, stopwords: set[str]) -> list[str]` 负责分词，先统一空白和标点，再使用 `jieba` 分词，并删除停用词、纯符号、纯数字和无意义的单字符外文片段

歌词清洗和分词的核心实现如下：

```
def clean_lyrics(lyrics: list[str]) -> str:
    valid_lines = []
    seen_lines = set()
    for line in lyrics:
        line = line.strip()
        if line == "" or ":" in line or "-" in line or line in seen_lines:
```

```

        continue
    valid_lines.append(line)
    seen_lines.add(line)
return "\n".join(valid_lines)

def tokenize(text: str, stopwords: set[str]) -> list[str]:
    text = re.sub(r"\s+", " ", text).lower()
    text = re.sub(r"[ , . ! ? ; : \ , . ! ? ; : ( ) \ [ \ ] 【 】 “ ” ‘ ’ … _ / ] +", " ", text)
    words = jieba.lcut(text, cut_all=False, HMM=True)
    tokens = []
    for word in words:
        word = word.strip()
        if (not word
            or word in stopwords
            or not any(char.isalnum() for char in word)
            or word.isdigit()
            or (len(word) == 1
                and not re.fullmatch(r"[\u4e00-\u9fff]", word))):
            continue
        tokens.append(word)
    return tokens

```

歌词词云和歌词聚类复用同一套清洗、停用词和分词规则，从而减少不同分析之间由预处理方式造成的偏差。

结论一：热门评论集中在晚间和午夜附近，0 点为单小时峰值

分析方法

`analysis/comment_time.py` 遍历每首歌曲的热门评论，检查评论正文和时间字段，将有效评论按发布时间的小时累计到长度为 24 的列表中，并计算该时段的评论数量、占比和单小时峰值。注：当前代码将 20、21、22、23 和 0 点定义为晚间时段。

相关核心代码如下：

```

NIGHT_HOURS = {20, 21, 22, 23, 0}
hour_counts = [0] * 24

for song in song_data:
    for comment in song["comments"]:
        if comment["text"].strip() == "":
            continue
        comment_hour = int(comment["time"]["hour"])
        if 0 <= comment_hour <= 23:
            hour_counts[comment_hour] += 1

valid_comment = sum(hour_counts)
night_comment = sum(hour_counts[hour] for hour in NIGHT_HOURS)
night_ratio = night_comment / valid_comment
peak_hour = max(HOURS, key=lambda hour: hour_counts[hour])

```


24 小时的原始数量保存到 `analysis/output/comment_hour/comment_hour_counts.csv`。

热门评论发布时间柱状图中，20 点至次日 0 点使用橙色，其余时段使用蓝色，并在图中标注占比和峰值。

数据结果

指标	结果
有效热门评论	19151 条
无效评论	0 条
20:00 至次日 00:59 的评论	6649 条
该时段占全部评论比例	34.72%
单小时峰值	0 点
0 点评论数	1527 条

晚间各小时的评论数为：20 点 1134 条、21 点 1289 条、22 点 1370 条、23 点 1329 条、0 点 1527 条。相比之下，凌晨 3 至 7 点的评论数明显较少，其中 5 点仅有 139 条。



结论

在本次抓取到的热门评论中，发布时间并非全天均匀分布。20 点以后评论数连续处于较高水平，20:00 至次日 00:59 的五个小时贡献了 34.72% 的评论，0 点又以 1527 条成为单小时峰值。由此可见，样本热门评论更集中在晚间休闲时段和午夜附近。

一个比较合理的解释是，晚上结束学习或工作以后，人们有更多完整的空闲时间，听歌、刷评论和分享感受都更方便。相比白天，晚间的环境也更安静，一些情绪较强的歌曲更容易让听众联想到自己的经历，从而产生评论的想法。0 点附近又正好处在很多人睡前使用手机的时间，因此评论数可能进一步增加。可以说，热门评论的高峰可能不只是“听歌人数多”，还和听众有时间停下来表达情绪、寻找共鸣有关。

结论二：歌词和热门评论的用词重点不同：歌词偏向作品表达，评论偏向评价与回应

分析方法

`analysis/wordcloud_analyse.py` 将歌词和热门评论作为两个独立语料集合。歌词先使用 `utils.clean_lyrics` 清洗，再用 `utils.tokenize` 分词并使用 `Counter` 计数；评论手动去掉空文本后，用 `utils.tokenize` 分词，再使用 `Counter` 计数。由于两类语料的总词数不同，程序除保存原始次数外，还计算每一万词出现次数：

```
lyrics_counter.update(tokens)
comments_counter.update(tokens)

counter_df = pd.DataFrame(
    counter.most_common(),
    columns=["token", "count"],
)
counter_df["count_per_1w"] = 10_000 * counter_df["count"] / total_tokens
```

歌词词频信息和评论词频信息保存到 `analysis/output/wordcloud` 下。

词云使用各自语料的每万词频率作为权重，左右两幅图使用相同的画布大小和最大词数。

语料统计

指标	歌词语料	评论语料
有效文本数	3821	19140
有效词语总数	354361	304699
不同词语数	41590	41224

选取与结论关系较强的词语进行比较：

词语	歌词每万词频	评论每万词频	主要差异
爱	82.57	51.13	歌词突出作品的核心情感内容
世界	22.41	15.79	歌词常用于构造叙事空间和意象
时间	16.06	11.65	歌词常写时间流逝和关系变化
回忆	15.07	8.76	歌词常进行情感回望
喜欢	8.21	62.39	评论明显更偏直接表达态度
好听	0.28	35.61	评论中多用评价用语
加油	0.20	6.07	评论包含对歌手或其他听众的支持
青春	4.43	10.83	评论常把歌曲与个人经历联系起来

词语	歌词每万词频	评论每万词频	主要差异
故事	7.08	9.68	评论常会讨论联歌曲与背后的故事

最终生成的词云图如下：



结论

从词频结果可以看出，歌词和热门评论的用词差异比较明显。歌词中的“爱、世界、时间、回忆”等词更突出，更多是在写感情、时间和故事；评论中的“喜欢、好听、加油”等词明显更多，主要是在评价歌曲、表达喜欢或表达支持。“青春”和“故事”在评论中也比较常见，说明听众会把歌曲和自己的经历联系起来。

这种差异和两类文本本身的作用是比较一致的。歌词需要完成歌曲的叙事和情感表达，所以会反复使用爱情、时间、回忆、世界等比较适合展开故事和情绪的词；评论则是听众听完歌曲之后的回应，因此更容易直接出现“喜欢”“好听”这样的态度词，以及“加油”这样的支持性表达。也就是说，评论并不是简单重复歌词中的内容，而是把歌曲转成了听众自己的评价和感受。

另外，值得注意的是，“青春”和“故事”在评论中的频率高于歌词。听众可能会因为一首歌想到以前的经历、某个阶段的人或事情，再把这些回忆写进评论区。从这个角度看，歌曲除了本身的作品表达之外，也可能成为听众回忆个人经历、和其他听众交流情绪的一个入口。

由此可见，这两类文本各有侧重：歌词主要是在表达歌曲本身的内容，评论更多是在评价和回应歌曲，以及表达共鸣。

结论三：歌词语义可以形成多个具有明确特征的聚类

分析方法

`analysis/lyrics_tsne.py` 执行以下流程：

- 清洗歌词并分词
- 过滤清洗后长度不足 30 字符的歌词，再将长歌词按照原有行顺序切分为最长 300 字符的文本块
- 使用预训练 embedding 模型 `BAAI/bge-small-zh-v1.5` 将每个文本块转化为 512 维向量
- 对同一首歌的文本块向量求平均并再次归一化，最终得到 3789 个歌曲向量。
- K-Means 将 512 维歌曲向量聚成 32 个 cluster

- 每个 cluster 的关键词由 cluster 内分词结果统计得到，典型歌曲则选取距离 K-Means 聚类中心最近的歌曲
- t-SNE 将歌曲向量投影到二维进行可视化

相关核心代码如下：

```
chunk_embeddings = model.encode(
    all_chunks,
    batch_size=BATCH_SIZE,
    normalize_embeddings=True,
    convert_to_numpy=True,
)


for chunk_embedding, song_idx in zip(chunk_embeddings, chunk_song_idx):
    song_embeddings[song_idx] += chunk_embedding
song_embeddings /= song_chunk_cnt[:, None]
song_embeddings /= np.linalg.norm(song_embeddings, axis=1, keepdims=True)

kmeans = KMeans(
    n_clusters=NUM_CLUSTERS,
    n_init=10,
    random_state=config.SEED,
)
labels = kmeans.fit_predict(song_embeddings)

song_coordinates = TSNE(
    n_components=2,
    perplexity=min(30, document_cnt),
    random_state=config.SEED,
    init="pca",
    learning_rate="auto",
).fit_transform(song_embeddings)
```

t-SNE 可视化图表中，按照 cluster 进行分类染色，得到如下结果：

歌词主题聚类 t-SNE可视化



各聚类主题与典型歌曲

下表展示全部 32 个 cluster 的信息摘要。其中典型歌曲选自距离 K-Means 聚类中心较近的歌曲。主题名称和分析是根据关键词、中心歌曲和歌词内容人工归纳的，重点比较不同 cluster 的区别。

Cluster	主题	歌曲数	典型歌曲	分析
0	追梦励志	114	《篇章》《最初的梦想》 《下一个天亮》	常出现梦想、飞翔、奔跑、勇敢等内容，整体比较积极。和 Cluster 20 相比，它更偏“坚持和前进”，不只写校园或少年生活。
1	多语舞曲	15	《Waka Waka》《Ojos Tristes》 《不潮不用花钱》	以英语、西班牙语等歌词和重复副歌为主，节奏感比具体故事更突出。
2	一生情歌	143	《当爱已成往事》《痴心换情深》 《此生不换》	更常写“一生、往事、永远”一类长期感情和旧情回忆。与 Cluster 3 的直接告白相比，这一簇更偏怀旧和长期承诺。
3	甜蜜告白	129	《Say U Love Me》《爱上你》 《我是真的爱上你》	主要是确认心意、表达爱和希望在一起，感情表达比较直接。与 Cluster 2 相比，它更接近恋爱开始或相处中的告白。
4	山河侠义	79	《庙堂之外》《小河淌水 1952》 《出山》	山河、江湖、家乡、历史和民俗等内容较多，重点是中国文化场景和故事。与 Cluster 6 都有国风特点，但 Cluster 6 更集中在古风爱情和相思。
5	星空浪漫	101	《星空叙爱曲》《渐暖》 《追光者》	常用星星、月亮、宇宙、夜空写心动和陪伴，整体比较温柔。和 Cluster 21、26 相比，这里的自然意象更偏浪漫，而不是失恋和离别。

Cluster	主题	歌曲数	典型歌曲	分析
6	古风相思	223	《锦鲤抄》《半生雪》《霜雪千年》	红尘、明月、天涯、相思、爱恨等古风词较集中，常写宿命、守候和离别。和 Cluster 4 相比，它更偏感情，不太强调历史或地域故事。
7	版权声明	64	《不知所措》《听悲伤的情歌》《说说话》	这个簇最明显的共同点不是歌词主题，而是“未经许可不得翻唱翻录或使用”等版权文字。它更像数据清洗后留下的格式簇，不能当成正常的歌词主题。
8	失恋遗忘	232	《我不难过》《制裁》《我不想忘记你》	多写分手、离开、哭、回忆和想忘记，关系通常已经破裂。和 Cluster 14 相比，这里更偏“分手以后”，而 Cluster 14 更偏关系还在反复拉扯。
9	故乡旅途	93	《起风了》《乘风》《故乡》	风、道路、天空、故乡、归来等词比较集中，常写出发、漂泊和回家。和 Cluster 11 相比，这一簇更突出“旅途”本身，生活压力和自我挣扎较少。
10	英语情感冲突	223	《Love The Way You Lie》《Stan》《We Belong Together》	主要是英语流行歌曲，常直接写争吵、伤害、依恋和分离。和 Cluster 12 相比，这一簇的人际冲突和对话感更强。
11	异乡漂泊	139	《飘向北方》《重生之我在异乡为异客》《平凡之路》	更常写异乡生活、压力、孤独和寻找方向，情绪比一般励志歌曲更沉重。和 Cluster 0、20 相比，它强调的是困境中的坚持。
12	英语回忆陪伴	154	《Memories》《Everglow》《Set Fire to the Rain》	同样以英语流行为主，但更常写时间、夜晚、回忆、失去和陪伴。和 Cluster 10 的冲突型情感相比，这一簇更偏回望和抒情。
13	季节离别	122	《不舍》《体贴》《她的眼睛会下雨》	秋风、落叶、雨雪、季节等自然意象较多，用来写思念和离别。和 Cluster 24 相比，它更依赖季节意象。
14	情感拉扯	154	《瘾》《周旋》《跳楼机》	常写依赖、失眠、沉默、疼痛和反复拉扯，情绪比较压抑。和 Cluster 8 相比，它不是单纯的分手回忆，而是更强调关系中的纠缠。
15	韩语抒情	67	《겁 (怯)》《Flower》《사랑이 잘 (爱情不太顺)》	主要是韩语抒情歌曲，内容包括孤独、分离、自省和鼓励。和 Cluster 22、25 相比，这一簇节奏感较弱，更重歌词叙述。
16	日语青春	50	《夜に駆ける》《Lemon》《群青》	主要按日语歌词聚集，常见青春、失去、记忆和自我选择。它首先是一个语言特征明显的簇，内部仍有多种子主题。
17	说唱态度	91	《玩世不恭》《VLOG》《发光弹》	主要是中文说唱，常写个人态度、名声、规则、兄弟和音乐理想。和 Cluster 19 相比，它更偏自我表达，不以恋爱和暧昧为中心。

Cluster	主题	歌曲数	典型歌曲	分析
18	粤语情感	123	《赛勒斯的爱》《续集》 《记忆棉》	粤语歌曲较多，常写旧爱、错失、复合和成年人的关系选择，表达比较克制。和 Cluster 27 相比，它更偏成熟反思，Cluster 27 的情感冲突更强。
19	暧昧说唱	65	《I Wanna Get Love》《想到你》 《你在哪里 (WYA)》	中英混合的说唱或 R&B 较多，常写吸引、约会、想念和主动追求。和 Cluster 17 相比，它明显更偏恋爱；和 Cluster 28 相比，它更偏暧昧和追求过程。
20	少年梦想	45	《快乐环岛》《梦的光点》 《大梦想家》	快乐、梦想、未来、少年、成长等词较多，整体明亮，有校园和偶像合唱的感觉。和 Cluster 0 相比，它更偏少年阶段的快乐和梦想。
21	雨夜思念	57	《岚》《下雨天》《给我一个理由忘记》	“雨、雨天、大雨、阴天”等词很集中，通常和孤独、想念、失恋连在一起。和 Cluster 13 相比，它几乎围绕“雨”这个意象展开，主题更集中。
22	韩语恋爱	87	《AS IF IT'S YOUR LAST》 《PLAYING WITH FIRE》 《SOLO》	主要是韩语偶像流行，内容偏心动、吸引、恋爱和自我魅力，副歌常夹有简短英语。和 Cluster 15 相比更外向，和 Cluster 25 相比更强调恋爱对象。
23	英语说唱	205	《Not Afraid》《Godzilla》 《The Monster》	主要是英语说唱，常写自我证明、名声、力量感和回归。和 Cluster 10、12 的英语情感歌曲相比，这一簇的第一人称态度和说唱表达更强。
24	青春回忆	153	《把回忆拼好给你》《感谢你曾来过》 《再遇见》	常出现再见、曾经、记得、过去、时间等词，重点是回头看已经结束的关系或青春。和 Cluster 13 相比，自然意象较少，回忆和告别本身更突出。
25	韩语舞曲	174	《Talk Saxy》《CASE 143》 《Not Shy》	主要是韩语偶像舞曲，重复英文短语、拟声词和命令式表达较多，舞台感很强。和 Cluster 22 相比，它更强调节奏、行动和自信，不只是在写恋爱。
26	海洋离别	52	《珊瑚海》《大海》《大鱼》	海、大海、海底、鱼、人海等词很集中，多用来写距离、等待和离别。和 Cluster 5 的星空意象相比，这一簇明显更伤感；和 Cluster 21 相比，核心意象从雨变成了海。
27	爱而不得	192	《爱得太迟》《春秋》《天后》	常写单向付出、错爱、后悔和来不及珍惜，关系失衡比较明显。和 Cluster 8 的分手遗忘相比，这里更突出“得不到”和“付出不对等”。
28	暗恋告白	128	《暗恋》《11》《唯一》	中英混合流行和说唱较多，常写暗恋、靠近、唯一和想要共同未来。和 Cluster 3 的直接告白相比，它更有都市说唱和暧昧感；和 Cluster 19 相比，关系表达更认真。

Cluster	主题	歌曲数	典型歌曲	分析
29	成熟情歌	158	《情歌王》《小宇》《诺言》	既写承诺、陪伴和幸福，也写寂寞、放手和失去，范围比较宽。和 Cluster 2 相比，它不只强调“一生”和怀旧；和 Cluster 8 相比，也不只集中在分手。
30	关系犹豫	77	《胆小鬼》《冷战》《想说爱你不容易》	常写想靠近又不敢、冷战、害怕受伤和自我怀疑。和 Cluster 3 的直接告白相反，这一簇最明显的特点就是犹豫和矛盾。
31	青春成长	80	《起风了》《老男孩》《春泥》	青春、春天、花、岁月、时光等词较多，常写成长以后回看过去。和 Cluster 20 相比，它更有回忆感；和 Cluster 24 相比，它又更突出成长和四季花开等意象。

结论与边界

从表中可以看出，即使都属于爱情歌曲，不同簇的侧重点也不一样。例如 Cluster 3 更偏直接告白，Cluster 8 更偏分手后的遗忘，Cluster 14 更偏关系中的拉扯，Cluster 27 更偏爱而不得，Cluster 30 则是想表达又不敢表达。自然意象也有明显区别：Cluster 5 主要是星空和月光，Cluster 21 主要是雨，Cluster 26 主要是海。外语歌曲中，语言和表达形式的作用也比较明显，例如英语情感歌曲、英语说唱、韩语抒情和韩语舞曲分别形成了不同的簇。

数据分析结果中，3789 首歌词并没有完全混在一起，而是分出了不少可以解释的簇。特别是几个相近的爱情主题还能继续分成告白、失恋、拉扯、爱而不得和犹豫等不同情况，说明歌曲之间的歌词语义差异并不只是在歌曲主题（例如爱情、自然、社会、人生等）这一层，歌词里的情境、情绪和常用意象也会形成更细的区别。梦想类歌曲也有类似现象：Cluster 0 更强调坚持和前进，Cluster 20 更偏少年时期的快乐和梦想，Cluster 11 则更多写现实压力下的漂泊和坚持。

由以上现象可以推断，embedding 得到的歌曲向量中，至少保留了一部分能够区分歌词内容的语义特征，使歌曲映射到高维向量空间中的位置较好地反映了歌曲的语义，K-Means 才能把相近但又不完全相同的歌曲精确分类。

同时，聚类也表现出了很强的语言和表达形式差异。日语歌曲、英语说唱、英语情感歌曲、韩语舞曲等分别成簇，说明模型判断相似性时，不只会受到“主题”影响，歌词使用的语言、写法和节奏化表达也会起作用。因此，这里的 cluster 更适合理解成“语义和表达方式相近的一组歌曲”，而不是严格的歌曲题材分类。

但并不是 32 个簇都同样清楚。Cluster 1 样本较少，而且有同一歌曲的不同版本；Cluster 13 也受到《侧脸》多个版本的影响；Cluster 7 更明显，主要是版权声明被一起聚了起来。这些现象说明，歌词中残留的非正文内容和重复版本也会被向量模型当成相似信息，进而影响聚类结果。

总结

本次分析从评论时间、词语使用和歌词语义三个角度得到以下结论：

- 1. 样本热门评论更集中在晚间和午夜附近。20:00 至次日 00:59 的评论占 34.72%，0 点以 1527 条成为单小时峰值。

2. 歌词和热门评论的用词重点不同。歌词更常出现“爱、世界、时间、回忆”等词，评论更常出现“喜欢、好听、加油、音乐、歌词”等评价和回应性词语。
3. 歌词语义可以形成多个具有明确特征的聚类。根据歌词语义，可识别出追梦励志、古风相思、失恋遗忘、故乡旅途、雨夜思念、海洋离别、说唱态度和多语种流行等主题或表达类型。

结论只描述本项目爬取到的样本，并保留热门评论非随机抽样、词频受分词规则影响、聚类受参数和文本质量影响等限制。